

About..

컴퓨터소프트웨어공학과 김 원 일





• 텀 프로젝트 진행

- R을 이용한 어떠한 형태의 데이터 분석도 허용
 - 웹 검색을 통해 작성해도 문제 없음
- 프로젝트 예제로 등록된 스크립트를 이용하거나 변형하여 작성해도 무방
- 작성된 프로젝트 스크립트는 unangel@yuhan.ac.kr 로 제출
- 제출 시 메일 제목: R 텀프로젝트 3학년 1반 201807001 김원일
 - 메일 검색을 위해 메일 제목은 통일
- 프로젝트 스크립트 파일 이름 : r_3_1_김원일.txt
- 제출 기한 : 12월 14일 밤 11시까지

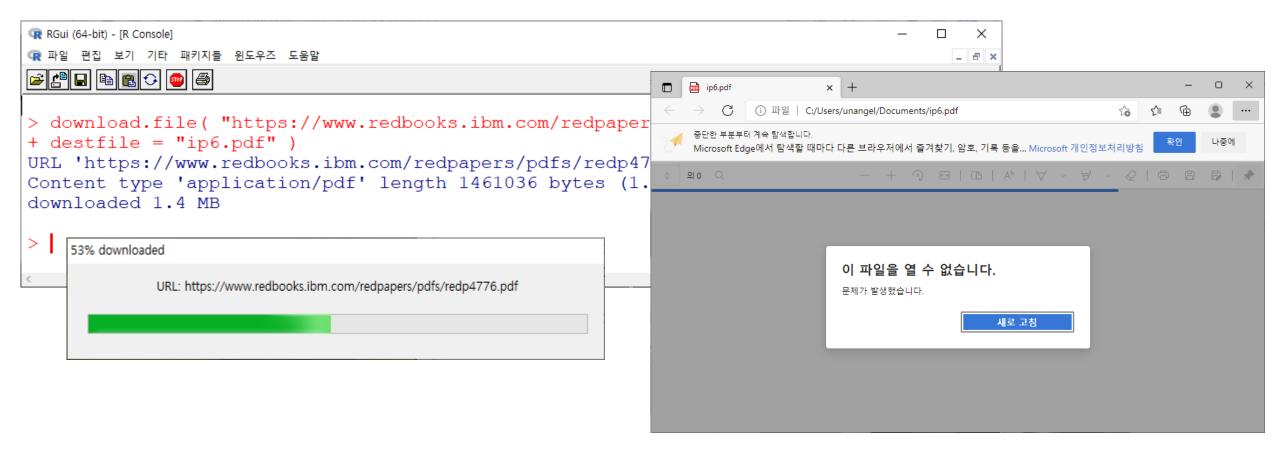
• 주의사항

- 특별한 패키지 등을 설치해야만 하는 경우, 관련 내용이 스크립트에 존재해야 함
- 시작부터 완료되는 시점까지 하나의 스크립트에서 모두 실행되어야 함



인터넷 파일 다운로드

- 전체 URL 주소로 파일 다운로드
 - download.file("URL", destfile = "저장할 파일명") 으로 파일을 저장할 수 있음





인터넷 파일 다운로드

• 파일 형식

- 일반 텍스트의 경우, download.file()로 쉽게 받을 수 있음 ex) https://www.ietf.org/rfc/rfc959.txt
- 바이너리 형식 파일은 바이너리 모드를 설정해야만 정상적으로 다운로드 가능
- mode = "wb" 로 설정하면, 바이너리 파일들도 모두 정상적으로 다운로드 가능

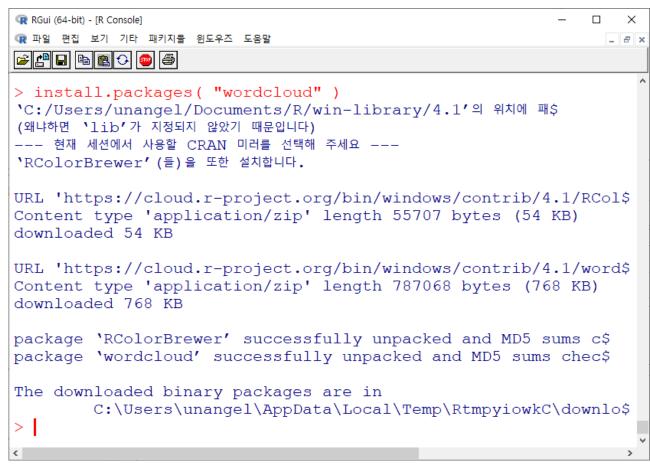




워드 클라우드 이용하기

- 워드 클라우드로 데이터 표현하기
 - 수집된 키워드를 바탕으로 중요도나 인기도 또는 출현 빈도를 이용하여 데이터를 출력하는 방법
 - "wordcloud" 패키지를 설치



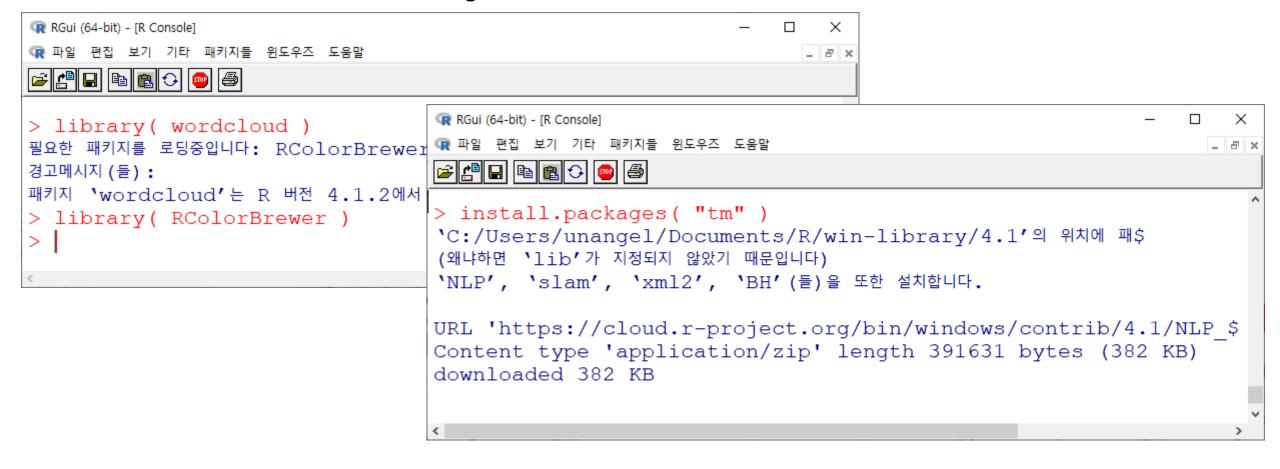




워드 클라우드 이용하기

• 패키지 로딩

- "wordcloud"와 "RColorBrewer"("wordcloud" 설치 시 자동 설치)를 모두 로딩
- "tm" 패키지도 설치 : Text Mining 패키지는 데이터에서 텍스트를 추출하여 처리하기 위해 필요



(Print Directory), and SYST (System).

INTRODUCTION

Note that this specification is compatible with the previous edition.

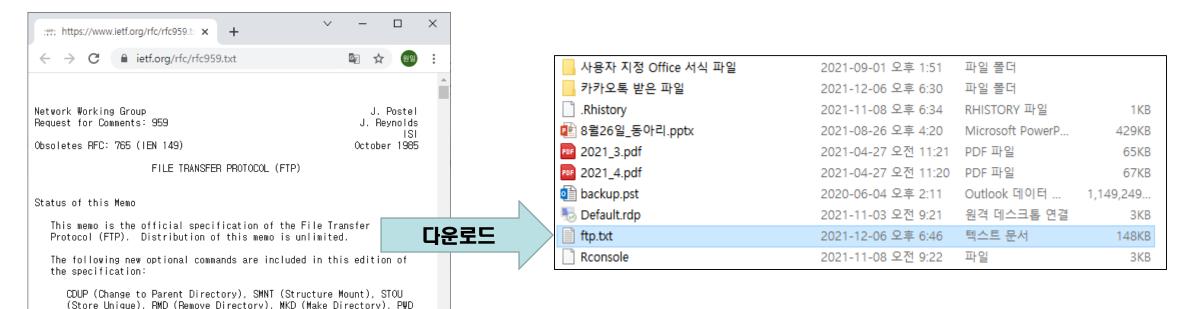
The objectives of FTP are 1) to promote sharing of files (computer programs and/or data), 2) to encourage indirect or implicit (via programs) use of remote computers, 3) to shield a user from variations in file storage systems among hosts, and 4) to transfer



워드 클라우드 이용하기

• 테스트 파일

- 일반적으로 많이 사용되고, 쉽게 구할 수 있는 문서를 활용
- RFP(request for proposal)는 요구사항 정리 문서로, 각종 프로토콜 또한 요구사항 문서가 존재
- "https://www.ietf.org/rfc/rfc959.txt" 에 FTP에 대한 요구사항이 존재





워드 클라우드 이용하기

• 파일 읽기

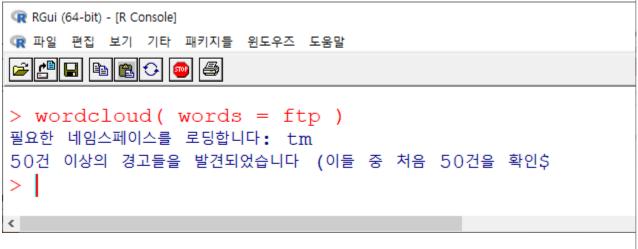
- readLines()를 통해 저장된 파일을 읽어 들임
- 유니코드 없는 텍스트이므로 빠르게 처리가 가능

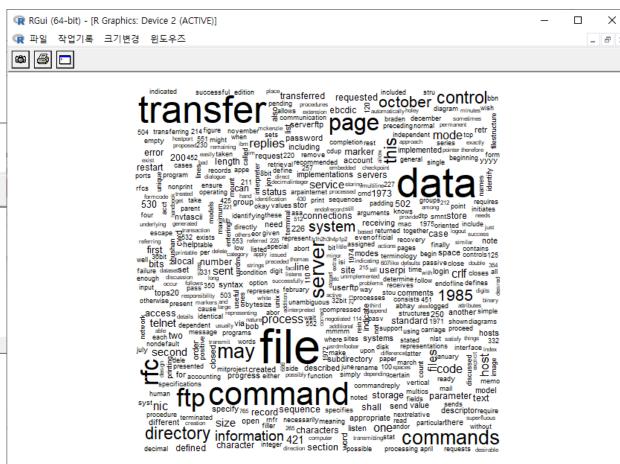
```
RGui (64-bit) - [R Console]
   편집 보기 기타 패키지들 윈도우즈 도움말
> ftp <- readLines( "ftp.txt" )</pre>
경고메시지(들):
readLines("ftp.txt")에서: 'ftp.txt'에서 불완전한 마지막 행이 발견되었습니다
> head( ftp )
[1]
[2]
[3] "Network Working Group
                                                                        J. Postel"
    "Request for Comments: 959
                                                                      J. Reynolds"
[5]
                                                                               ISI"
[6] "Obsoletes RFC: 765 (IEN 149)
                                                                     October 1985"
```



🦫 워드 클라우드 이용하기

- wordcloud로 표현
 - (words = ftp)로, 읽어 들인 일반 문자열을 별도의 처리 없이 단순하게 표현이 가능
 - 내부적으로 "tm" 패키지를 로딩하여 사용
 - 반드시 "tm" 패키지가 설치되어 있어야 함



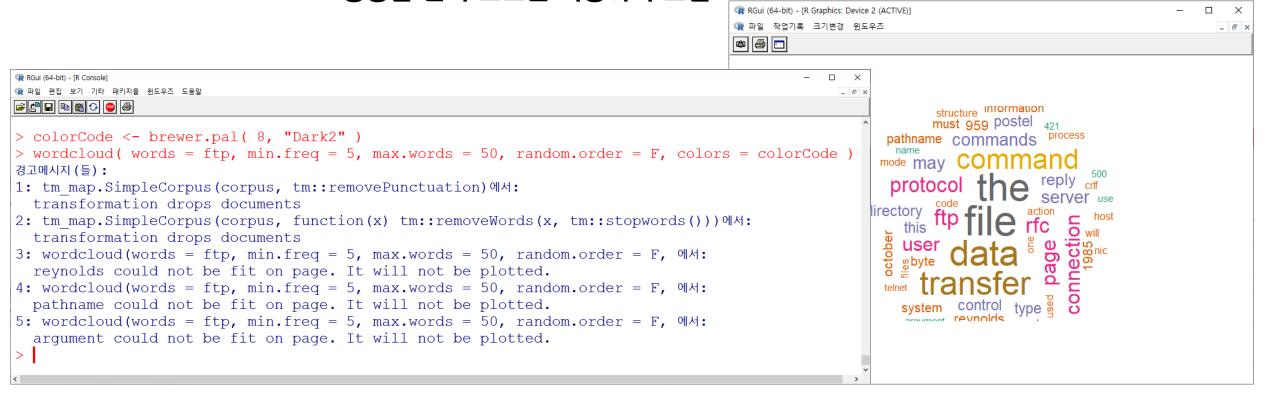




워드 클라우드 이용하기

• 옵션 사용

- min.freq : 최소 몇 번 이상 등장해야 하는지 여부 설정
- max.words : 표현하려는 최대 단어 개수
- random.order : 고빈도 단어 중앙배치 여부
- colors = colorCode : 생성한 컬러 코드를 이용하여 표현





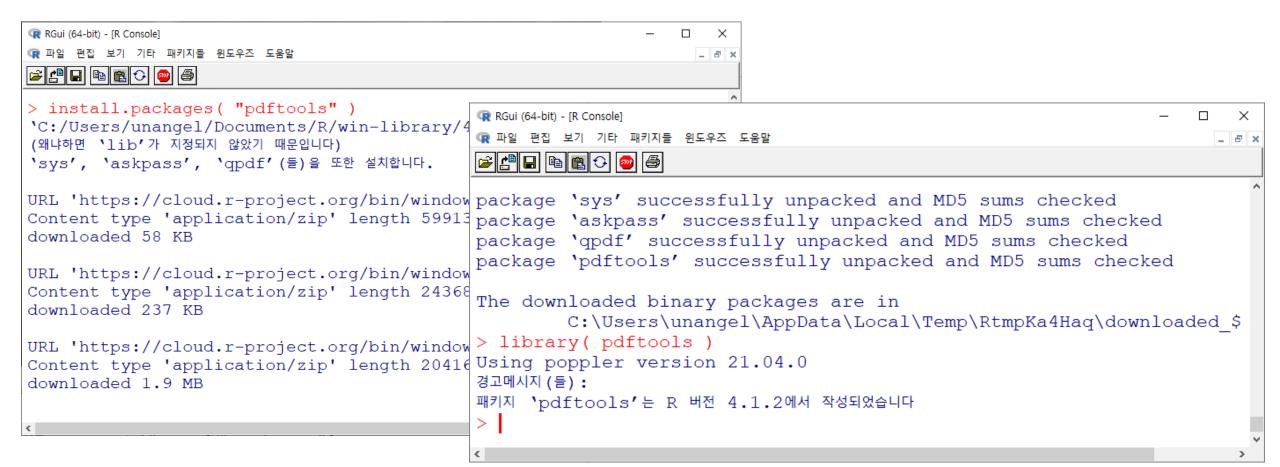
• 인터넷에서 파일을 받아 워드 클라우드로 표현하기

```
😱 RGui (64-bit)
                                         파일 작업기록 크기변경 윈도우즈
                                         🛎 🗿 🗖
# 워드 클라우드 라이브러리 로딩
                                                                                                  - - X
                                                                       R Graphics: Device 2 (ACTIVE)
Library (wordcloud)
# 분석할 파일 다운로드
Download.file( "https://www.ietf.org/rfc/rfc959.txt", destfile = "ftp.txt")
# 다운로드 받은 파일 읽기
r959 <- readLines( "ftp.txt" )
# 색상 테이블 작성
color <- brewer.pal( 8, "Dark2" )</pre>
# 워드 클라우드 생성
wordcloud( words = r959, min.freq = 5, max.words = 200,
        random.order = F, colors = color)
```



PDF 패키지 설치

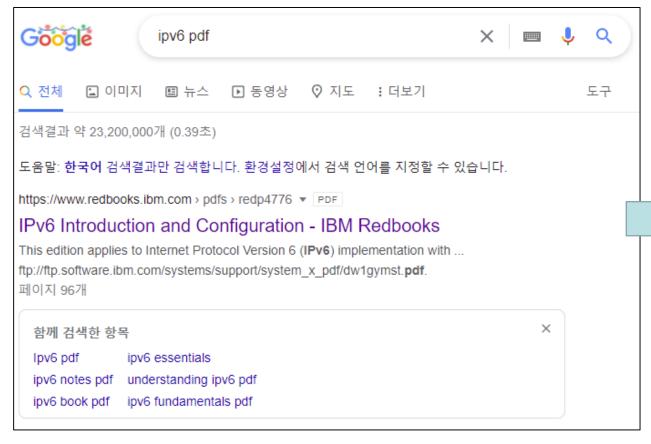
- "pdftools" **패키지 설치 및 로드**
- 로드 후, pdf_test(pdf, opw, upw) 형식으로 PDF 문서를 읽어 들일 수 있음

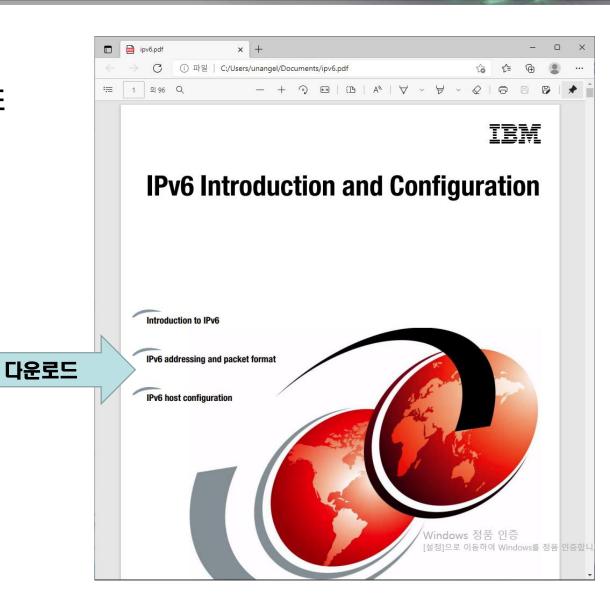




PDF **파일 읽기**

- PDF 문서 다운로드
 - "ipv6 pdf"로 검색하여 첫 번째 PDF 파일을 다운로드
 - **파일 이름을** "ipv6.pdf"로 저장







PDF **파일 읽기**

• PDF **읽기**

- pdf_text("ipv6.pdf")로 PDF 문서를 변수로 읽기
- PDF 문서를 뷰어에서 보는 것과 달리 텍스트만을 추출하여 획득

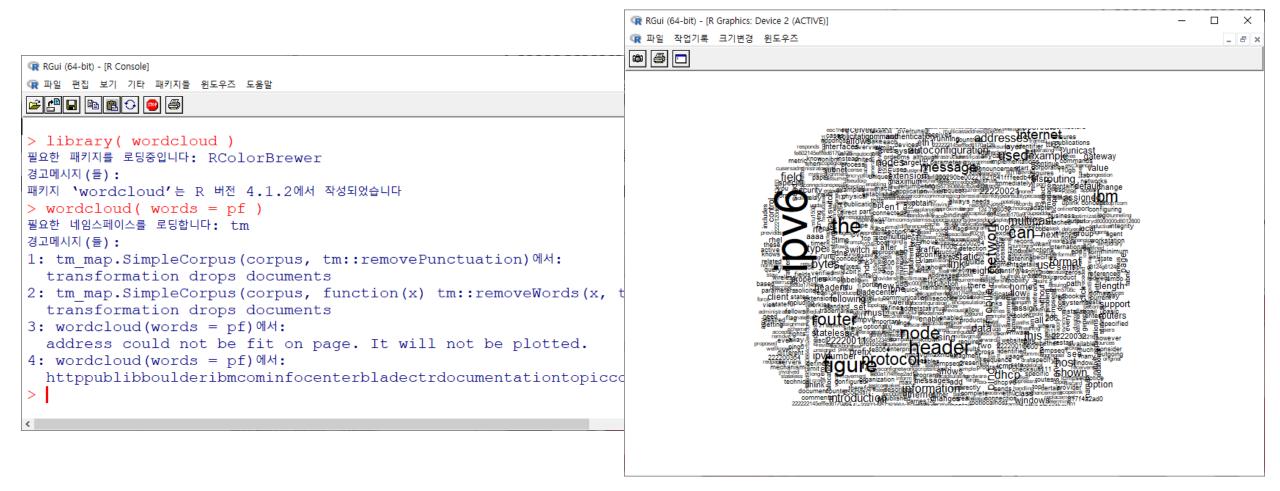
_

```
RGUI (64-bit)-[R Console]

REPLIENT PLANT PROPERTY PROPE
```



- wordcloud 로 문서 내용 표시
 - 단순히 읽어 들인 데이터를 그대로 전달해도 생성





- 분석할 PDF 문서 다운로드
 - 위키백과에서 원하는 항목을 PDF 파일 형식으로 다운로드
 - 다운로드 한 파일을 작업 디렉터리로 이동
 - 접근이 쉽도록 간단한 이름으로 변경

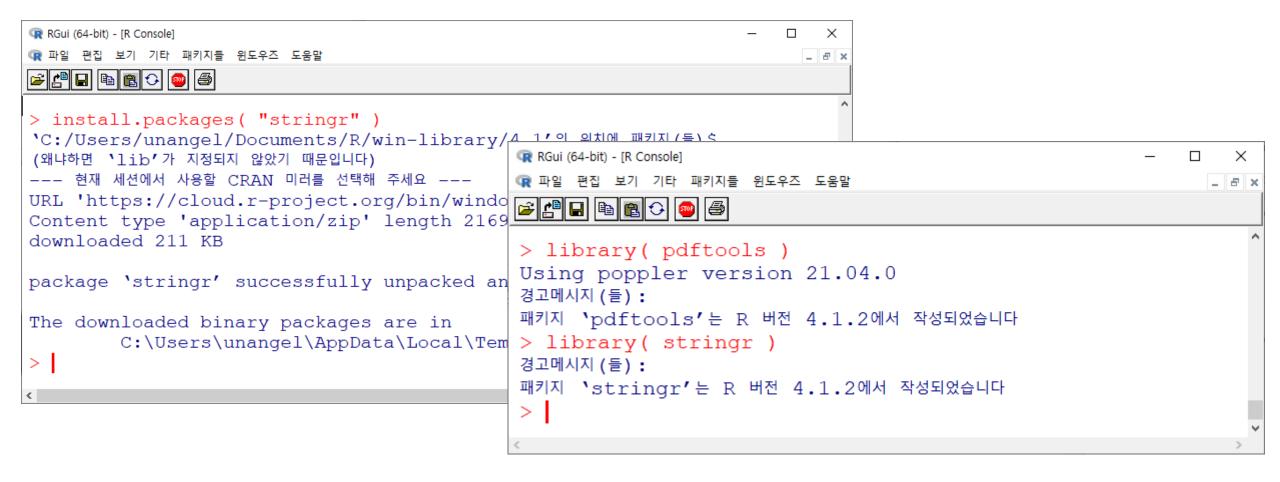






• 패키지 설치 및 로드

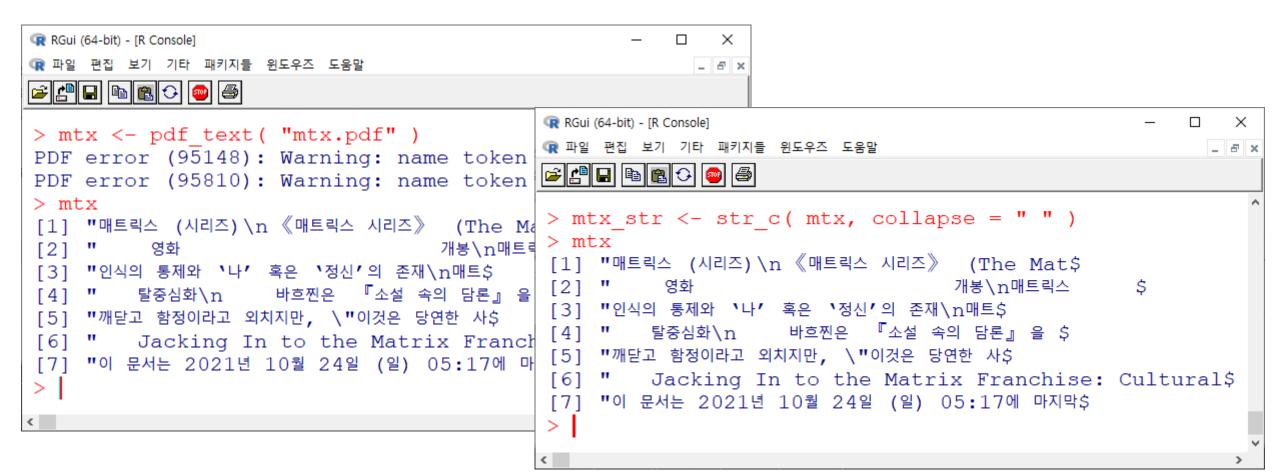
- pdftools와 stringr 패키지를 설치하고, 로드





• 읽은 문서 전처리

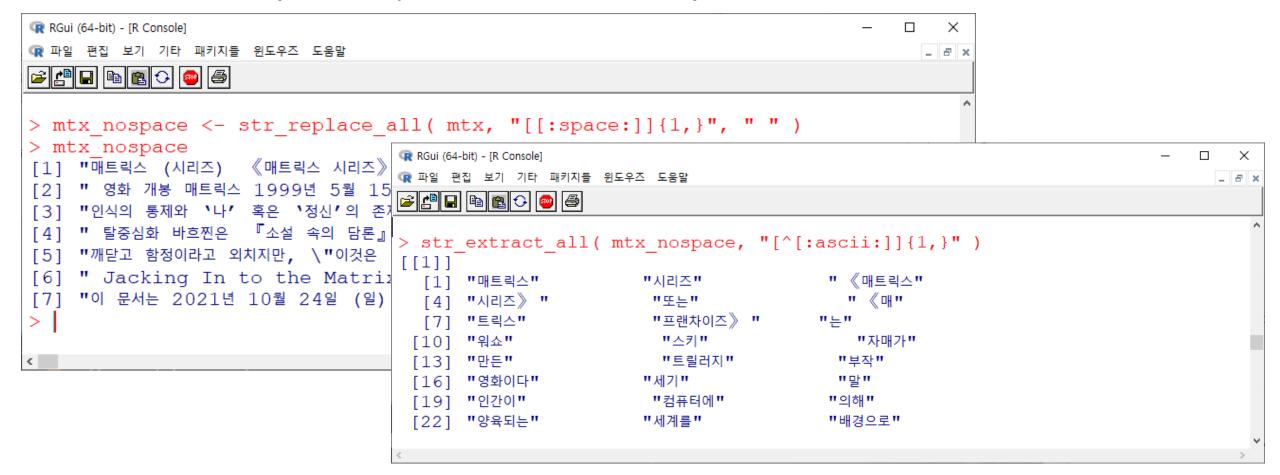
- str_c(data, collapse = " ")로 데이터 전처리 수행
- 공백을 기준으로 문장이 분리되도록 구성. 내용은 크게 차이가 없는 것으로 나타남





• 읽은 문서 전처리

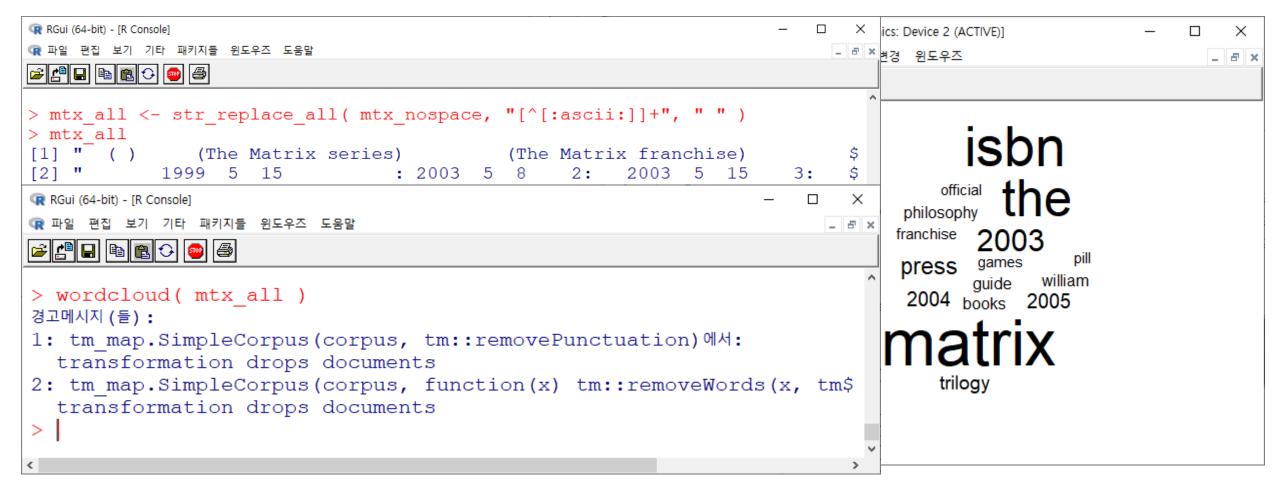
- str_replace_all(mtx, "[[:space:]]{1,}", " ") 문장으로 2개 이상의 공백을 하나의 공백으로 치환
- str_extract_all(mtx_nospace, "[^[:ascii:]]{1,}") 문장으로 ASCII 코드 외의 문자열 확인





• 전처리 완료 및 워드 클라우드 생성

- str_replace_all(mtx_nospace, "[^[:ascii:]]+", " ") 으로 제외할 문자들을 공백으로 대체





```
# 워드 클라우드, 문자열처리 라이브러리 로딩
Library(pdftools)
Library(stringr)
#저장한 PDF 문서를 읽음
Mtx <- pdf_text( " mtx.pdf " )</pre>
# 문자열을 분리
Mtx_str <- str_c( mtx, collapse = " " )
# 공백으로 데이터 처리
Mtx_nospace <- str_replace_all( mtx, " [[:space:]]{1,} ", " " )</pre>
# 한글 및 특수기호 데이터를 공백으로 대체
mtx_all <- str_replace_all( mtx_nospace, "[^[:ascii:]]+", " ")
# 워드 클라우드 실행
wordcloud( mtx_all )
```



🧇 구글 트랜드 사용하기

- 구글 트랜드
 - 트랜드 검색어의 정보와 검색 시기 등에 대한 정보를 제공하는 사이트
 - https://trends.google.com/trends/?geo=KR

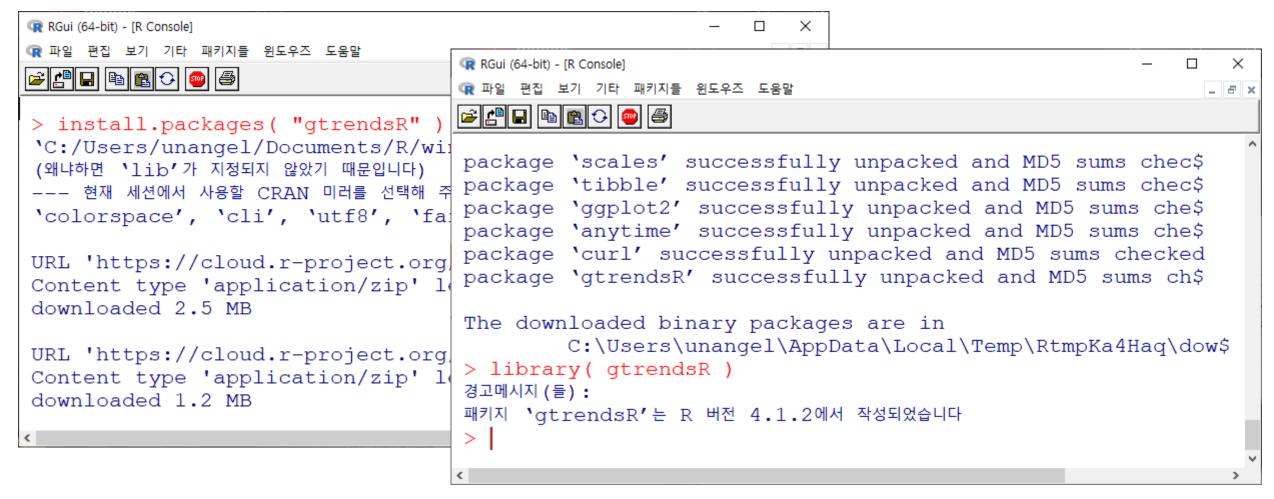




🤛 구글 트랜드 사용하기

• 패키지 설치와 로드

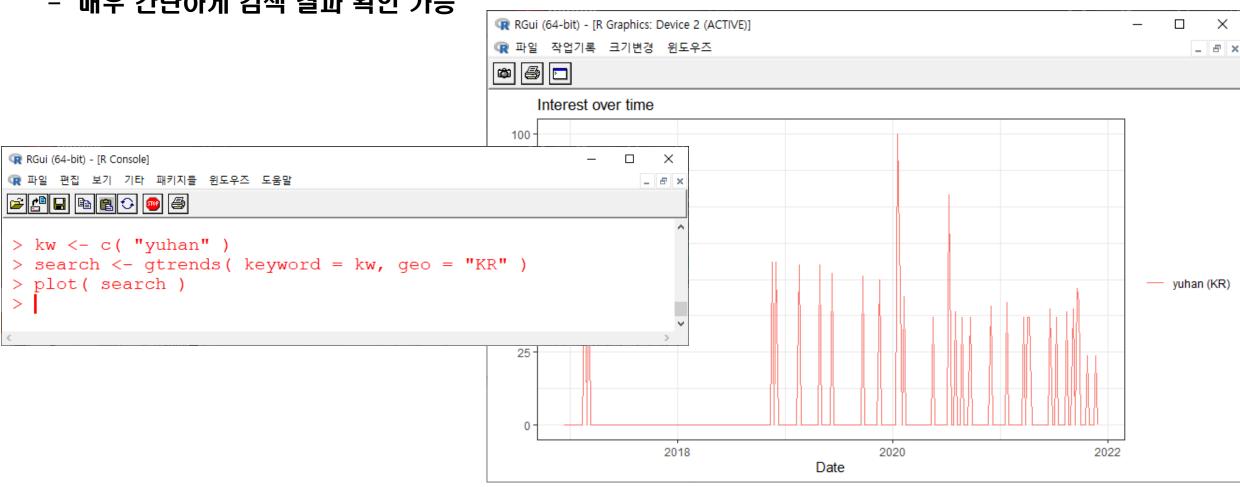
- "gtrendsR" **패키지를 설치** 후, 로딩





🧇 구글 트랜드 사용하기

- "yuhan" 키워드 검색 트랜드 확인
 - 매우 간단하게 검색 결과 확인 가능

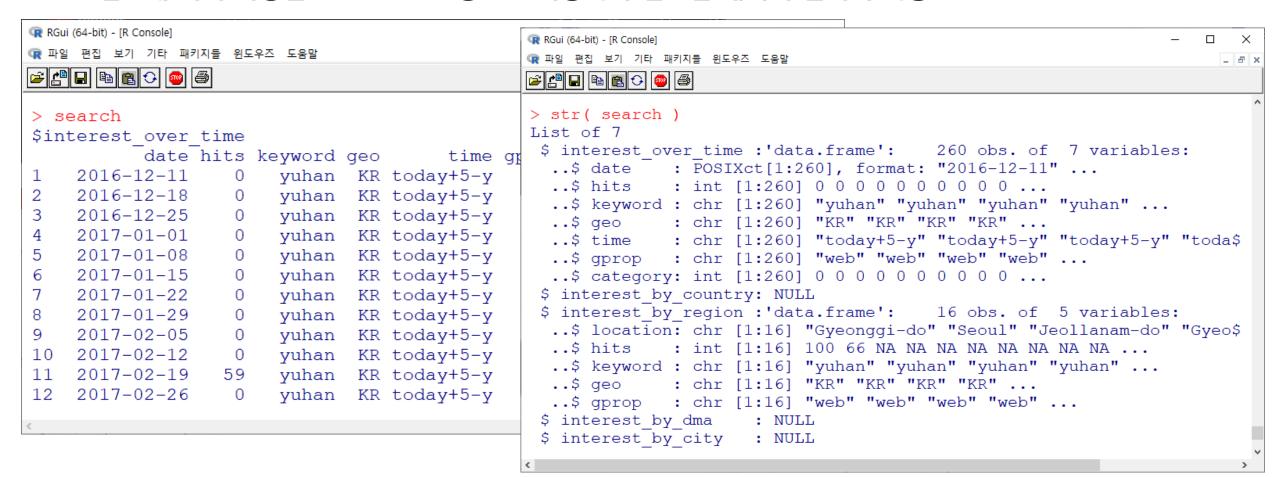




🦫 구글 트랜드 사용하기

• 내부 데이터 셋 구조

- 검색어와 관련된 7개의 data frame으로 구성됨
- 필요에 따라 다양한 data frame 정보를 이용하여 필요한 데이터 분석이 가능





🧇 구글 트랜드 사용하기

• 데이터 검색

- 2017년 초반부터 현재까지의 데이터를 모두 획득하여 반환
- 전 세계에서 검색된 내용을 모두 수집하여 반환
- 검색 조건으로 필요한 데이터 수집 😱 파일 작업기록 크기변경 윈도우즈 Interest over time 100 RGui (64-bit) - [R Console] 보기 기타 패키지들 윈도우즈 도움말 75 Search hits > kw <- c("bmw", "audi", "porche")</pre> > search <- gtrends(kw)

RGui (64-bit) - [R Graphics: Device 2 (ACTIVE)]

2018

2020

Date

audi (world)

bmw (world) porche (world)

2022



🧇 구글 트랜드 사용하기

• 검색 조건

- geo : 지역(국가) 설정

- time : 검색어 확인 날짜 기준

